

Detección Temprana de Caídas de Red en Switches de Distribución Universitarios Mediante Análisis de Zero-Ratio y Aprendizaje Automático

Juan Manuel Velosa Valencia

Programa de Ingeniería Telemática, Universidad Icesi, Cali, Colombia
Director: Nicolás Salazar, Andres Navarro | Correo: anavarro@icesi.edu.co

RESUMEN

Este artículo presenta una metodología para la clasificación de caídas en interfaces de red de la capa de distribución del campus de la Unidad Central del Valle del Cauca (UCEVA), distinguiendo entre fallas reales de infraestructura y silencios de tráfico atribuibles a estacionalidad institucional. Se analizaron dos conjuntos de datos, uno de seis horas con muestras cada dos minutos (1.000 interfaces, 261 activas, 86 con eventos de fallo, 724 ocurrencias detectadas) y uno extendido del 18 de marzo al 17 de abril de 2026, con muestras cada 15 minutos, que permitió observar estacionalidad semanal y comportamientos anómalos prolongados. Se propone el indicador Zero-Ratio (ZeroRatio) como señal primaria de clasificación, definido como la proporción de lecturas de tráfico nulo en una ventana deslizante. Frente a alternativas como la media móvil de tráfico y la desviación estándar en ventana, el ZeroRatio demostró mayor interpretabilidad y sensibilidad ante silencios sostenidos, al ser independiente de la magnitud absoluta del tráfico. El análisis exploratorio sobre el conjunto inicial estableció que un ZeroRatio mayor o igual a 0.6 precede consistentemente a los eventos de fallo; para el conjunto extendido de 30 días con sondeo cada 15 minutos, el umbral fue refinado a 0.75, en combinación con un criterio de duración mínima de cuatro polls consecutivos (60 minutos) y verificación explícita del contexto temporal (día hábil, horario laboral de 07h a 18h, ausencia de festivo). El etiquetado se realizó mediante reglas deterministas aplicadas sobre el comportamiento histórico ya observado, sin uso de información futura, un evento se clasificó como falla real solo si el silencio cumplía simultáneamente el criterio de duración mínima y ocurría en contexto laboral; el mismo silencio en fin de semana, festivo o fuera de horario laboral se clasificó como estacionalidad. Las interfaces sin tráfico medible durante todo el periodo de observación fueron descartadas del entrenamiento por no aportar información discriminativa. Se evaluaron cinco modelos de clasificación supervisada: Regresión Logística, Árbol de Decisión, Random Forest, XGBoost y una red LSTM implementada desde cero en NumPy, con doce características agrupadas en variables históricas de ZeroRatio, indicadores de estacionalidad cíclica y comparaciones contra baselines históricos, con partición temporal estricta 50/50. La Regresión Logística obtuvo el mejor F1-score global (0.89), seguida del LSTM (0.83), el Árbol de Decisión (0.74), el Random Forest (0.73) y XGBoost (0.58). Los primeros cuatro modelos superaron el umbral objetivo de F1-score de 0.70, mientras que XGBoost no lo alcanzó debido a un recall de tan solo 0.41, pese a lograr precisión perfecta (1.00). Los resultados validan que el ZeroRatio combinado con clasificadores supervisados constituye un enfoque práctico para la gestión proactiva de fallos en redes universitarias, sentando además las bases metodológicas para una futura extensión predictiva del sistema.

Palabras clave: Análisis de tráfico de red, aprendizaje automático, clasificación de fallos, estacionalidad del tráfico, gestión proactiva de redes, monitoreo SNMP, Zero-Ratio.

I. INTRODUCCIÓN

La confiabilidad de la infraestructura de red es determinante para el funcionamiento de entornos universitarios, donde la continuidad del servicio impacta directamente las actividades académicas y administrativas. Los switches de la capa de distribución agregan el tráfico proveniente de dispositivos de acceso y lo reenvían hacia el núcleo, una falla en esta capa puede provocar la pérdida de conectividad de múltiples dependencias de forma simultánea. La gestión proactiva de fallos busca anticipar los eventos antes de que se manifiesten, permitiendo tomar medidas preventivas y reducir el tiempo de inactividad [3]. La predicción en línea de fallos basada en el monitoreo continuo del estado del sistema ha emergido como una alternativa técnicamente viable cuando se dispone de telemetría confiable [3]. El tráfico de red presenta propiedades estadísticas que dificultan su modelado, Paxson y Floyd [2] demostraron empíricamente que los procesos de llegada de paquetes y conexiones TCP de área amplia no se ajustan a distribuciones de Poisson. El tráfico exhibe dependencia a largo plazo, auto-similitud y distribuciones de cola pesada, lo que implica que períodos transitorios de tráfico nulo no pueden interpretarse trivialmente como fallos sin considerar el contexto temporal e histórico del enlace [2]. Esta propiedad estadística fundamenta el uso de ventanas temporales deslizantes y el análisis de

estacionalidad como componentes esenciales de cualquier sistema de detección de fallos.

El presente trabajo aborda la detección de caídas en interfaces de switches de distribución de la red del campus UCEVA a partir de series de tiempo de tráfico recolectadas mediante SNMP. Se propone el indicador (ZeroRatio) como señal predictora liviana e interpretable, y se evalúan cinco clasificadores de aprendizaje automático.

A. Objetivos

El objetivo de esta investigación es desarrollar y comparar modelos de clasificación supervisada capaces de distinguir, a partir de métricas de tráfico obtenidas por SNMP, entre fallas reales de infraestructura y silencios de tráfico ocasionados por la estacionalidad en la red, con el fin de optimizar el monitoreo proactivo de redes universitarias y reducir falsas alarmas.

Los objetivos específicos son:

- 1) Realizar un análisis exploratorio del tráfico histórico de interfaces activas.
- 2) Desarrollar modelos de clasificación de caídas en la red.
- 3) Comparar los modelos de clasificación desarrollados.
- 4) Evaluar el desempeño mediante métricas estándar de los modelos.

II. TRABAJOS RELACIONADOS

Paxson y Floyd [2] analizaron 21 trazas de tráfico TCP de área amplia y evidenciaron que los modelos de llegada de Poisson son válidos únicamente para sesiones iniciadas por usuarios (TELNET, FTP), mientras que otros procesos como las conexiones FTPDATA y NNTP muestran desviaciones significativas respecto a la distribución exponencial. El tráfico exhibe mayor capacidad de ráfaga que la predicha por modelos Poisson en múltiples escalas temporales, e incluso el tráfico agregado de área amplia muestra indicios de auto-similitud. Esto implica que los períodos sostenidos de tráfico nulo no pueden interpretarse trivialmente como indicadores de fallo sin considerar patrones históricos y estacionalidad del enlace.

Wang et al. [1] propusieron un método de monitoreo y predicción de fallos en redes ópticas combinando Máquinas de Soporte Vectorial (SVM) con suavizamiento exponencial doble (DES), alcanzando una precisión media del 95%. Su trabajo demostró que los algoritmos de aprendizaje automático pueden operar con volúmenes de datos históricos relativamente limitados, relevante en entornos institucionales con registros de fallos escasos.

Salfner et al. [3] ofrecieron una taxonomía exhaustiva de métodos de predicción de fallos en línea. Un hallazgo central fue que la selección de características tiene mayor influencia sobre la precisión de predicción, que la elección del algoritmo clasificador, lo que motivó directamente la estrategia de ingeniería de características adoptada en este trabajo.

III. CONJUNTO DE DATOS Y ANÁLISIS EXPLORATORIO

A. Base de Datos Inicial (Ventana de Seis Horas)

El primer conjunto de datos se obtuvo mediante sondeo SNMP de los switches de distribución del campus UCEVA, registrando la tasa de tráfico de salida de 1.000 interfaces cada dos minutos durante una ventana continua de seis horas. El análisis reveló que 739 interfaces (73,9%) estuvieron completamente inactivas, mientras que 261 (26,1%) presentaron tráfico activo. De estas interfaces activas, 86 (32,9%) exhibieron al menos un evento de caída, totalizando 724 anomalías. La Figura 1 muestra la evolución temporal del promedio de interfaces activas.




Fig. 1. Evolución temporal del promedio de interfaces activas durante la ventana de observación de seis horas.

Para comprender los patrones previos a una caída, se analizaron tres interfaces del switch NETSW008: gi1, gi2 y gi14. La Figura 2 muestra la evolución temporal del tráfico en cada una. La interfaz NETSW008/gi14 presentó frecuencia de caídas notablemente superior, motivando un análisis detallado de su comportamiento.




Fig. 2. Evolución temporal del tráfico en las interfaces gi1, gi2 y gi14 del switch NETSW008 durante la ventana de seis horas.

B. Base de Datos Extendida (30 Días)

Con el fin de observar el comportamiento de los enlaces durante un período suficiente para capturar estacionalidad semanal y distinguir caídas reales de patrones ocupacionales, limitación identificada en la base de datos inicial [2] se replicó el proceso de análisis con un segundo conjunto de datos. Este comprende registros SNMP de las mismas interfaces de switches de distribución, tomados cada 15 minutos entre el 18 de marzo de 2026 a las 16:15 y el 17 de abril de 2026 a las 15:58, cubriendo aproximadamente 30 días de operación.

Para el análisis de comportamiento se seleccionaron tres interfaces de dos switches de distribución, del primer switch, BLOQUE_C-FACINGENIERIA-SW1, tenemos las interfaces BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 y BLOQUE_C-FACINGENIERIA-SW1/Gi0/10, del segundo switch SW-DC-FO, tenemos la interfaz SW-DC-FO/Te0/35.

La Figura 3 muestra la evolución temporal del tráfico en estos tres enlaces durante el período completo.




Fig. 3. Evolución temporal del tráfico en las interfaces BLOQUE_C-FACINGENIERIA-SW1/Gi0/13, Gi0/10 y SW-DC-FO/Te0/35 durante el periodo extendido de 30 días.

Las interfaces BLOQUE_C-FACINGENIERIA-SW1/Gi0/10 y SW-DC-FO/Te0/35 exhibieron un comportamiento normal, con las únicas excepciones esperables del lunes festivo del 23 de marzo (día de San José) y los días de Semana Santa (del jueves 9 al lunes 13 de abril), donde el tráfico disminuyó de forma coherente con la reducción de actividad universitaria. Estas disminuciones, resaltadas en rojo en la figura, corresponden a estacionalidad legítima y no deben clasificarse como fallos. En contraste, la interfaz BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 presentó un comportamiento anómalo, registró tráfico normal entre el 18 y el 20 de marzo, seguido de un período de tráfico prácticamente nulo hasta el 7 de abril, fecha a partir de la cual retomó actividad con un patrón repetitivo. No obstante, durante el periodo del 9 al 13 de abril se registró paradójicamente un volumen de tráfico elevado, comportamiento inverso al de los otros dos enlaces. Esta anomalía sostenida de más de dos semanas constituye un evento de estacionalidad prolongado genuino, diferenciable de las falsas alarmas (resaltadas en amarillo) que corresponden a desconexiones transitorias de dispositivos.

La extensión temporal de la base de datos permitió corroborar que el comportamiento bursty y la auto-similitud del tráfico documentados por Paxson y Floyd [2] se manifiestan claramente en los enlaces del campus, las variaciones periódicas semanales (días hábiles vs. festivos) generan patrones de tráfico nulo que, sin contexto histórico, serían indistinguibles de eventos de fallo mediante umbrales estáticos.

IV. INDICADOR ZERO-RATIO PARA DETECCIÓN DE FALLOS

A. Selección y Justificación del Indicador

Se evaluaron como alternativas la media móvil y la desviación estándar; la primera es sensible a la magnitud absoluta del tráfico y la segunda no distingue entre alta variabilidad y silencio sostenido. El ZeroRatio () supera estas limitaciones al ser independiente de la escala, binario en su cómputo y directamente interpretable como la fracción de tiempo en silencio. Esta propiedad lo hace robusto ante interfaces heterogéneas y computacionalmente liviano para su cálculo en tiempo real vía SNMP, sin requerir almacenar la serie completa.

B. Definición Formal

El ZeroRatio se define como la proporción de lecturas de tráfico nulo dentro de las muestras más recientes de una interfaz, donde f es la función indicadora y λ la tasa de tráfico en el paso i . En el conjunto inicial (sondeo cada 2 min), el criterio de fallo se basa en rachas de 3 pasos consecutivos en cero (6 min). Para el conjunto extendido de 30 días (sondeo cada 15 min), se calculan las ventanas (4 pasos, 60 min) y (2 pasos, 30 min) como características del vector de entrada.

C. Umbral y Análisis de Precursor

La interfaz NETSW008/gi14 motivó la construcción del perfil precursor de la Figura 4. Este se calculó sobre los 708 eventos de fallo detectados en todo el conjunto de seis horas (que tenían 20 min de historial), promediando sus 10 pasos (20 min) previos, normalizados respecto al tráfico máximo de esa subventana. La media muestra una caída sostenida y progresiva al aproximarse el fallo. Se determinó que el ZeroRatio promedio en interfaces sanas es 0.3, y que un valor 0.6 anticipa consistentemente la caída. La Figura 4 confirma esta inflexión monótona a través de la curva de media normalizada y su rango intercuartil (banda sombreada).




Fig. 4. Tasa media normalizada de eventos en ventanas de 20 minutos según el estado del ZeroRatio ($ZR \geq 0.6$ frente a $ZR < 0.6$).

D. Distribución de la Duración de los Fallos

Los eventos de fallo se categorizaron según su duración en: breves (10 min), moderados (11–30 min) y prolongados (30 min). La Figura 5 detalla esta distribución de frecuencias y el tiempo acumulado de indisponibilidad. Los datos revelan que la mayoría

de los eventos en el conjunto inicial fueron breves, lo que se asocia con desconexiones transitorias de usuarios más que con fallas estructurales de infraestructura. La Figura 5 muestra la distribución por categoría y el tiempo total acumulado por interfaz. La mayoría de los eventos inicialmente detectados eran breves y correspondían a falsas alarmas.




Fig. 5. Número de eventos de fallo agrupados por intervalos de duración y categoría de severidad.

E. Falsas Alarmas y ZeroRatio Ajustado

En el conjunto extendido, la interfaz BLC-SW1/Gi0/17 evidenció silencios breves y aislados por desconexiones transitorias de dispositivos, mientras que SW-CREPIDS/Gi0/8 presentó un silencio prolongado y sostenido característico de una falla real de hardware, compartiendo un patrón superficialmente similar en su fase inicial. Dado que el tráfico de red exhibe ráfagas y dependencia temporal [2], los periodos breves de tráfico nulo no constituyen evidencia de fallo por sí solos. La incorporación de un criterio de duración mínima al ZeroRatio permite suprimir estos eventos espurios sin requerir reglas adicionales (Figura 6). Este diagnóstico de fallo físico en SW-CREPIDS/Gi0/8 fue validado por el tutor de grado, Nicolás Salzar, quien confirmó que este comportamiento es similar a un escenario real que hubo de un puerto de switch dañado que provocó exactamente este patrón de degradación.




Fig. 6. Evolución del ZeroRatio, umbral ajustado y eventos detectados en escenarios de falla real y silencio transitorio.

V. CLASIFICACIÓN MEDIANTE APRENDIZAJE AUTOMÁTICO

A. Ingeniería de Características

Se derivaron doce características a partir de las series de tiempo de tráfico de cada interfaz del conjunto extendido, siguiendo el principio de Salfner et al. [3], la calidad de las características determina el desempeño del modelo. Las características se organizan en tres grupos según su naturaleza, resumidos en la Tabla 1.

Grupo 1. Características Históricas de Actividad

Capturan el comportamiento reciente de la interfaz en la ventana de polls ya observada. `zr4` expresa el ZeroRatio en los últimos cuatro polls (60 minutos). `zr2` lo hace para los dos polls más recientes (30 minutos), detectando cambios abruptos. `std4` corresponde a la desviación estándar de la tasa de tráfico en los mismos cuatro polls, un valor elevado indica variabilidad normal, mientras que `std4` aproximadamente igual a 0 junto con `zr4` mayor o igual a 0.75 caracteriza el silencio prolongado. `consec_z` contabiliza el número de polls consecutivos en cero acumulados hasta el timestamp actual, recorriendo la serie hacia atrás hasta el primer valor distinto de cero, esta característica implementa directamente el criterio de duración mínima para distinguir silencios transitorios de fallos prolongados. `delta1` recoge la variación de tráfico entre el poll actual y el inmediatamente anterior, capturando la dirección del cambio.

Grupo 2 Características de Estacionalidad Temporal

Proporcionan al modelo el contexto temporal necesario para determinar si un silencio de tráfico es esperado o anómalo. La hora del día y el día de la semana se codifican mediante transformaciones seno-coseno circulares. Esta codificación es necesaria porque las variables temporales son cíclicas, la hora 23 y la hora 0 son consecutivas en el ciclo diario, pero si se representan como enteros (23 y 0) el modelo percibiría una distancia de 23 unidades entre ellas, cuando en realidad entre las 11pm y 12am solo hay una hora. Al proyectarlas sobre el círculo unitario mediante seno y coseno, se preserva la continuidad del ciclo, horas adyacentes resultan cercanas en el espacio de características, independientemente de si cruzan la medianoche o el cambio de semana. Para aterrizar esto matemáticamente, aplicamos seno y coseno a las horas y días de la semana de la siguiente manera: $\text{hour_sin} = \sin(2\pi \text{hora}/24)$, $\text{hour_cos} = \cos(2\pi \text{hora}/24)$, $\text{dow_sin} = \sin(2\pi \text{dow}/7)$, $\text{dow_cos} = \cos(2\pi \text{dow}/7)$. El indicador binario `is_weekend` toma el valor 1 los sábados y domingos. Estas cinco características permiten a los clasificadores aprender que un ZeroRatio elevado en domingo a las 3am no tiene el mismo significado operativo que el mismo valor un martes a las 10am, lo cual es precisamente el mecanismo mediante el cual el sistema distingue estacionalidad de falla real.

Grupo 3. Características de Comparación con Baselines Históricas

Los baselines se calculan una sola vez al inicio del pipeline a partir de las interfaces activas, para cada día de la semana y para cada hora del día se promedia el tráfico positivo histórico de todo el periodo. (`zr_vs_dow_baseline`) relaciona el ZeroRatio actual con la actividad esperada para ese día de la semana, un valor alto indica que el silencio es desproporcionado respecto al patrón histórico. `hour_activity` normaliza a [0, 1] el nivel de tráfico

esperado para la hora actual respecto al máximo histórico de cualquier hora, valores cercanos a 1.0 corresponden a horas de alta actividad esperada (10h a 16h), mientras que valores próximos a 0.0 indican horas de baja actividad histórica (2h a 5h). Por ejemplo, el análisis de baselines del conjunto extendido mostró que el tráfico medio de los jueves es considerablemente superior al de los domingos, coherente con procesos institucionales de respaldo ejecutados en días hábiles.

Tabla 1. Características del vector de entrada para los clasificadores.

Característica	Grupo	Descripción	Rango
<code>zr4</code>	Histórico	Desv. estándar de tráfico en 4 polls	[0, 1]
<code>zr2</code>	Histórico	Polls consecutivos en cero hasta t	[0, 1]
<code>std4</code>	Histórico	Variación de tráfico entre poll t y t-1	[0, +inf)
<code>consec_z</code>	Histórico	Seno de la hora del día	[0, +inf)
<code>delta1</code>	Histórico	Coseno de la hora del día	(-inf, +inf)
<code>hour_sin</code>	Estacionalidad	Seno del día de la semana	[-1, 1]
<code>hour_cos</code>	Estacionalidad	Coseno del día de la semana	[-1, 1]
<code>dow_sin</code>	Estacionalidad	Indicador binario de fin de semana	[-1, 1]
<code>dow_cos</code>	Estacionalidad	ZeroRatio actual vs. baseline del día de la semana	[-1, 1]
<code>is_weekend</code>	Estacionalidad	Nivel de actividad esperada para la hora actual	{0, 1}
<code>zr_vs_dow_baseline</code>	Baseline	ZeroRatio actual vs. baseline del día de la semana	[0, +inf)
<code>hour_activity</code>	Baseline	Nivel de actividad esperada para la hora actual	[0, 1]

Antes de alimentar los modelos, el vector de doce características se escala mediante StandardScaler ajustado exclusivamente con los datos de entrenamiento. El LSTM recibe adicionalmente los datos en formato tridimensional (número de muestras $\times$ 4 pasos $\times$ 12 características),

construyendo para cada timestamp una ventana histórica de cuatro pasos consecutivos ya observados.

B. Modelos Evaluados

Se entrenaron y compararon cinco modelos de clasificación supervisada: (1) Regresión Logística [4], (2) Árbol de Decisión [5], (3) Random Forest [6], (4) XGBoost [7] implementado desde cero en NumPy mediante gradient boosting con árboles y función de pérdida log-loss, y (5) una red LSTM [8] implementada desde cero en NumPy mediante retropropagación a través del tiempo (BPTT) y optimización Adam, sin dependencias de frameworks de aprendizaje profundo. Los modelos (1) a (3) utilizan las implementaciones de scikit-learn con balanceo de clases (`class_weight='balanced'`); todos se evaluaron con partición temporal estricta 50/50 y un umbral de decisión fijo de 0.70 aplicado a las probabilidades predichas, sin ajuste por conjunto. El ZeroRatio con criterio de duración mínima sirvió como línea base comparativa, al no requerir entrenamiento supervisado.

VI. RESULTADOS Y DISCUSIÓN

La Figura 7 presenta, para cada uno de los cinco modelos evaluados sobre el conjunto de validación, Para cada modelo se muestran tres barras agrupadas en el orden: precisión, recall y F1-score. La línea roja discontinua en 0.70 delimita el umbral mínimo aceptable.




Fig. 7. Métricas de evaluación (precisión, recall y F1-score) obtenidas por los cinco modelos de clasificación.

A. Interpretación de Métricas de Evaluación

Las tres métricas empleadas cuantifican aspectos complementarios del desempeño de los clasificadores. La precisión mide la proporción de alertas de falla emitidas que corresponden efectivamente a fallas reales; un valor bajo implica un alto número de falsas alarmas, lo que en un entorno operativo genera fatiga en el equipo de monitoreo. El recall mide la proporción de fallas reales que el modelo detecta; un recall bajo significa que eventos de falla genuinos pasan desapercibidos, exponiendo la red a interrupciones no gestionadas. Dado que ambas dimensiones tienen consecuencias operativas, el F1-score se adopta como métrica integradora al constituir la media armónica entre precisión y recall.

Regresión Logística obtuvo una precisión de 0.89, un recall de 0.88 y un F1-score de 0.89, siendo el modelo con el mejor equilibrio global. Este resultado evidencia que las doce características propuestas, en particular la codificación cíclica de hora y día y la comparación con baselines históricos, proporcionan señales suficientemente discriminativas para que un clasificador lineal supere el umbral objetivo. Su limitación estructural es la asunción de relaciones lineales entre las características y el logaritmo de la probabilidad de falla, lo que deja margen de mejora respecto a modelos no lineales en escenarios de mayor variabilidad.

Árbol de Decisión logró una precisión de 0.95, un recall de 0.61 y un F1-score de 0.74. Su alta precisión indica que cuando emite una alerta de falla acierta en el 95% de los casos; sin embargo, su recall de 0.61 revela que deja sin detectar el 39% de las fallas reales. Este comportamiento es característico de los árboles cuando operan con umbrales de decisión estrictos, priorizando la pureza del nodo a costa de la cobertura.

Random Forest alcanzó una precisión de 0.73, un recall de 0.59 y un F1-score de 0.73. Aunque el promediado de múltiples árboles reduce la varianza individual y produce fronteras de decisión más estables, el recall de 0.59 es incluso menor al del Árbol de Decisión individual, lo que sugiere que la diversidad del ensamble no compensó la pérdida de sensibilidad sobre el conjunto de validación con las características actuales.

XGBoost obtuvo la precisión más alta de todos los modelos (1.00), pero su recall de 0.41 resultó en un F1-score de 0.58, el único modelo que no superó el umbral objetivo. Una precisión perfecta implica que ninguna de las alertas emitidas fue una falsa alarma; sin embargo, un recall de 0.41 significa que XGBoost pasó por alto el 59% de las fallas reales, lo que lo hace inviable para un sistema de monitoreo donde la omisión de fallas tiene consecuencias operativas directas. Esta brecha es atribuible a que XGBoost, operando con restricciones computacionales que limitaron el subconjunto de entrenamiento disponible, tiende a clasificar como negativos los casos de baja confianza, sacrificando sensibilidad en favor de especificidad.

La red LSTM obtuvo una precisión de 0.97, un recall de 0.73 y un F1-score de 0.83, posicionándose como el segundo modelo con mayor F1-score. Su alta precisión indica que casi todas las alertas emitidas corresponden a fallas reales, mientras que su recall de 0.73 supera al de los métodos basados en árboles, reflejando que la ventana histórica de cuatro pasos captura adecuadamente la dinámica temporal inmediatamente previa al evento clasificado. Los 30 días de la base extendida resultaron suficientes para alcanzar un desempeño competitivo, aunque por su naturaleza secuencial el LSTM se beneficiaría de un mayor volumen de datos etiquetados en escenarios de mayor variabilidad.

B. Análisis de Falsas Alarmas y Diferenciación Estacional

Una de las contribuciones más relevantes del sistema propuesto es su capacidad para distinguir dos fenómenos que producen patrones de tráfico superficialmente idénticos, la falla real de infraestructura y la disminución estacional del tráfico. Esta distinción se articula mediante dos mecanismos complementarios.

El criterio de contexto temporal determina si un silencio de tráfico ocurre en un periodo donde la actividad de la red debería ser nula por razones institucionales (festivo, fin de semana, fuera de horario laboral); cuando esto se cumple, el sistema clasifica el silencio como estacionalidad y no emite alerta. El criterio de duración mínima establece que solo los silencios sostenidos durante cuatro o más intervalos de muestreo consecutivos, en contexto laboral, califican como falla real.

Los enlaces Gi0/10 y SW-DC-FO/Te0/35 presentaron patrones de tráfico nulo coherentes con la estacionalidad institucional, correctamente identificados como no-falla por los clasificadores gracias a las características temporales cíclicas. El enlace Gi0/13, con su anomalía sostenida de más de dos semanas y su comportamiento inverso durante Semana Santa, fue correctamente señalado como falla genuina, demostrando que el modelo captura no solo la presencia de silencio sino también su incongruencia con el patrón histórico esperado para ese día y hora.

Respecto a los falsos positivos, el principal riesgo identificado es la herencia de contexto en la frontera entre el horario nocturno y el inicio del día laboral, un silencio iniciado en domingo puede acumular polls consecutivos en cero suficientes para superar el umbral de duración al llegar el lunes, siendo potencialmente clasificado como falla en el primer intervalo laboral. Este efecto se mitiga con la característica `consec_z` en combinación con la codificación cíclica de la hora, que permite a los modelos basados en árboles reconocer que el silencio se inició fuera del horario de riesgo. En cuanto a los falsos negativos, el sistema presenta una limitación estructural ante degradaciones severas que no producen tráfico absolutamente nulo, interfaces con volumen residual de paquetes que no incrementan el ZeroRatio no activan el mecanismo de clasificación, lo que representa una dirección de mejora para versiones futuras.

C. Confiabilidad del Modelo para Escenarios Reales de Monitoreo

Los resultados validan que el sistema propuesto es confiable para la problemática planteada en las condiciones del experimento. La metodología de partición temporal estricta 50/50 simula fielmente el escenario de despliegue real, garantizando que las métricas reportadas no están infladas por filtración de datos. El escalado estándar ajustado exclusivamente con datos de entrenamiento refuerza esta garantía.

La confiabilidad del modelo en producción está acotada a interfaces que exhiban patrones de tráfico con estacionalidad semanal e institucional comparable a la observada en la red UCEVA. Factores como festivos no incluidos en el catálogo de características, ventanas de mantenimiento programado o degradaciones parciales sin tráfico absolutamente nulo podrían incrementar la tasa de errores de clasificación respecto a los valores reportados.

El ZeroRatio con criterio de duración mínima mantiene la ventaja de no requerir datos etiquetados de entrenamiento, lo que lo hace desplegable inmediatamente en nuevos segmentos de red. Los clasificadores supervisados, por su parte, capturan patrones más complejos gracias al vector de doce características, logrando mayor F1-score y menor tasa de falsas alarmas. Esta complementariedad sugiere un esquema híbrido para entornos de producción, emplear el ZeroRatio ajustado como mecanismo de

clasificación inmediata sin historial e introducir progresivamente los clasificadores supervisados a medida que se acumula y etiqueta el historial de eventos, manteniendo en todo caso un reentrenamiento periódico con partición temporal estricta.

VII. CONCLUSIONES

Este artículo propuso y evaluó una metodología basada en el indicador Zero-Ratio para la clasificación de fallas reales frente a estacionalidad en interfaces de switches de distribución universitarios, validada en dos conjuntos de datos de la red UCEVA, una ventana inicial de seis horas y una base extendida de 30 días con muestras cada 15 minutos.

El análisis de la base extendida confirmó que el tráfico de red exhibe estacionalidad semanal e institucional que genera periodos de tráfico nulo estructuralmente similares a las fallas, validando empíricamente el planteamiento de Paxson y Floyd [2] sobre la inadecuación de modelos estáticos sin contexto temporal. La interfaz

BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 representó un caso de falla prolongada real, de más de dos semanas, diferenciable de los silencios estacionales transitorios por su duración y por su comportamiento atípico frente a la estacionalidad observada en los otros enlaces. En el conjunto inicial, el análisis sobre 708 eventos de fallo confirmó un patrón de caída de tráfico sostenida y consistente en los minutos previos al evento, validando al ZeroRatio como señal de clasificación robusta.

De los cinco modelos de clasificación evaluados, cuatro superaron el umbral objetivo de F1-score de 0.70. La Regresión Logística obtuvo el mejor balance global con precisión 0.89, recall 0.88 y F1-score 0.89. La red LSTM alcanzó precisión 0.97, recall 0.73 y F1-score 0.83. El Árbol de Decisión logró precisión 0.95, recall 0.61 y F1-score 0.74. El Random Forest obtuvo precisión 0.73, recall 0.59 y F1-score 0.73. XGBoost fue el único modelo que no superó el umbral, con precisión de 1.00 pero recall de 0.41 y F1-score de 0.58. La tasa controlada de falsas alarmas en los modelos aprobados confirmó que la incorporación del contexto temporal es suficiente para discriminar la estacionalidad institucional de la degradación real de infraestructura en el entorno evaluado.

Como trabajo futuro, la principal línea de extensión consiste en incorporar capacidad predictiva al sistema, de modo que, además de clasificar correctamente un silencio de tráfico ya observado, sea capaz de anticipar la ocurrencia de una falla con antelación suficiente para ejecutar acciones preventivas. Para ello se explorarán arquitecturas de predicción de series de tiempo, como LSTM multistep y modelos autoregresivos, entrenados sobre el historial de ZeroRatio y las características temporales ya definidas en este trabajo, con el objetivo de estimar la probabilidad de falla en los próximos intervalos de muestreo antes de que el silencio se manifieste por completo. Adicionalmente, se abordarán dos limitaciones estructurales identificadas, la detección de degradaciones severas que no producen tráfico absolutamente nulo, y el despliegue en tiempo real sobre el servidor de monitoreo SNMP de la UCEVA, con reentrenamiento periódico bajo partición temporal estricta.

RECONOCIMIENTOS

El autor agradece al Equipo de Operaciones de Red de la Unidad Central del Valle del Cauca por facilitar el acceso a los datos de monitoreo de switches, y a los directores Nicolás Salazar y Andrés Navarro por su orientación a lo largo del proyecto.

REFERENCIAS

- [1] Z. Wang, M. Zhang, D. Wang, C. Song, M. Liu, J. Li, L. Lou y Z. Liu, "Failure prediction using machine learning and time series in optical network," *Opt. Express*, vol. 25, n.º 16, pp. 18553–18565, ago. 2017, DOI: 10.1364/OE.25.018553.
- [2] V. Paxson y S. Floyd, "Wide-area traffic: the failure of Poisson modeling," *ACM SIGCOMM Comput. Commun. Rev.*, vol. 24, n.º 4, pp. 257–268, oct. 1994, DOI: 10.1145/190809.190338.
- [3] F. Salfner, M. Lenk y M. Malek, "A survey of online failure prediction methods," *ACM Comput. Surv.*, vol. 42, n.º 3, pp. 10:1–10:42, mar. 2010, DOI: 10.1145/1670679.1670680.
- [4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: sklearn.linear_model.LogisticRegression. [En línea]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html
- [5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: Decision Trees. [En línea]. Disponible: <https://scikit-learn.org/stable/modules/tree.html>
- [6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: Ensemble Methods – Random Forests. [En línea]. Disponible: <https://scikit-learn.org/stable/modules/ensemble.html#forest>
- [7] T. Chen y C. Guestrin, "XGBoost: A Scalable Tree Boosting System," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, San Francisco, CA, 2016, pp. 785–794, DOI: 10.1145/2939672.2939785. Documentación oficial. [En línea]. Disponible: <https://xgboost.readthedocs.io/en/stable/>
- [8] PyTorch Contributors, "torch.nn.LSTM," *PyTorch Documentation*, versión 2.12. [En línea]. Disponible: <https://docs.pytorch.org/docs/2.12/generated/torch.nn.LSTM.html>

AUTOR

Juan Manuel Velosa Valencia es estudiante del Programa de Ingeniería Telemática de la Universidad Icesi, Cali, Colombia. Este trabajo fue desarrollado como proyecto de grado bajo la dirección de Nicolás Salazar y Andrés Navarro. Sus intereses de investigación incluyen el monitoreo de redes, la clasificación de eventos mediante aprendizaje automático y la gestión proactiva de infraestructuras de telecomunicaciones.